

Multisensor-LiDAR-Objekterkennung in einer Tiefgarage

Training, Cross-Validation und Bewertung von PointPillars und CenterPoint auf zwei Einzelsensoransichten und einer fusionierten Punktwolke

Experiment-held-out 3-Fold-Cross-Validation · Person, Fahrrad und Auto · Vergleich von os0, os1 und merged · Fehleranalyse und Laufzeiteinordnung

PROJEKT

Multisensor LiDAR 3D Object Detection

STAND

16. Juli 2026

DOKUMENTSTATUS

Erster Entwurf · Version 0.1

HAUPTMODELL

PointPillars · KITTI-Finetuning

Inhaltsverzeichnis

Kurzfassung

1. Aufgabenstellung und Forschungsfragen

2. Datengrundlage

2.1 Sensoraufbau und Ansichten · 2.2 Aufgezeichnete Experimente · 2.3 Annotationen

3. Datenaufbereitung und Sensorfusion

3.1 Registrierung und Merge · 3.2 Konvertierung in das Trainingsformat

4. Modelle und Training

4.1 PointPillars · 4.2 Klassenungleichgewicht und GT-Sampling · 4.3 Architekturvergleich mit CenterPoint

5. Evaluationsprotokoll

5.1 Warum der frühere temporale Split ersetzt wurde · 5.2 Experiment-held-out Cross-Validation · 5.3 Metriken · 5.4 Fold-Mittel und gepoolte Out-of-Fold-Auswertung · 5.5 Offizielle und labelbasierte Beweg-/Statisch-Auswertung

6. Ergebnisse

6.1 Gesamtleistung von PointPillars · 6.2 Bewegte Objekte · 6.3 Warum ist Fahrrad-AP30 bei os0 höher? · 6.4 Offizielle dynamische Auswertung und AP60-Artefakt · 6.5 Vergleich zu CenterPoint

7. Qualitative Fehleranalyse

7.1 Definition der Geisterboxen · 7.2 Plausible Ursachen · 7.3 Praktische Gegenmaßnahmen

8. Laufzeit

8.1 Modellinferenz · 8.2 Merge-Zeit und Ende-zu-Ende-Einordnung

9. Gültigkeit und Grenzen

9.1 Interne Gültigkeit · 9.2 Einschränkungen der Aussagekraft

10. Schlussfolgerung

11. Reproduzierbarkeit und Projektartefakte

11.1 Zentrale Implementierungen · 11.2 Primäre Ergebnisquellen · 11.3 Präsentationsmaterial

12. Offene Arbeiten

Kurzfassung

In diesem Projekt wurde untersucht, wie gut vortrainierte neuronale Netze zur dreidimensionalen Objekterkennung auf eine fest installierte Zwei-Sensor-LiDAR-Anlage in einer Tiefgarage angepasst werden können. Die Zielklassen sind Person, Fahrrad und Auto. Verglichen wurden die beiden Einzelsensoransichten `os0` und `os1` sowie die aus beiden Sensoren erzeugte fusionierte Punktwolke `merged`.

Als Hauptmodell wurde PointPillars eingesetzt und ausgehend von einem auf KITTI vortrainierten Drei-Klassen-Checkpoint für 50 Epochen auf den Projektdaten finetuned. Wegen des starken Klassenungleichgewichts wurde eine ausschließlich aus Trainingsdaten erzeugte GT-Sampling-Datenbank verwendet. Die abschließende Bewertung folgt einer vor der Ergebnissichtung eingefrorenen gepaarten 3-Fold-Cross-Validation. In jedem Fold werden drei vollständige Experimente – je eines für Auto, Fahrrad und Person – als ungesehene Testaufnahmen zurückgehalten.

PointPillars erreicht mit der fusionierten Ansicht in jedem Fold den höchsten Gesamt-mAP. Der Fold-Mittelwert beträgt $0,798 \pm 0,037$ für `merged`, $0,777 \pm 0,018$ für `os0` und $0,770 \pm 0,027$ für `os1`. Der Vorteil der Fusion ist damit nicht sehr groß, aber über alle Folds konsistent. Besonders deutlich ist er bei der Lokalisierung von Personen und Fahrrädern. Das bewegte Auto wird dagegen in allen drei Ansichten zuverlässig erkannt; `os0` ist bei AP30 sogar leicht besser. Die frühere Aussage, `os1` könne das bewegte Auto grundsätzlich nicht erkennen, beruhte auf einem positionskonfundierten temporalen Split und ist nicht mehr gültig.

Die fusionierte Punktwolke benötigt auf der Evaluations-GPU ungefähr `85 ms` pro Modellinferenz, gegenüber `45 ms` für `os0` und `43 ms` für `os1`. Diese Messung belegt die 10-Hz-Fähigkeit der Modellinferenz, nicht jedoch die Echtzeitfähigkeit des vollständigen Fusionssystems. Die vorhandene Offline-Merge-Pipeline benötigt im Median `2,25 s` pro Frame, weil sie Rauschfilterung, Normalenschätzung und ICP für jeden Frame erneut ausführt. Ein optimierter Online-Merge mit einmalig bestimmter Extrinsik wurde noch nicht gemessen.

1. Aufgabenstellung und Forschungsfragen

Die Ausgangssituation ist eine fest installierte Verkehrsszene in einer Tiefgarage, die gleichzeitig von zwei LiDAR-Sensoren aus unterschiedlichen Perspektiven erfasst wird. Das Projekt soll ein vortrainiertes 3D-Objekterkennungsmodell auf diese Zielszene anpassen und den Nutzen der Multisensorfusion quantifizieren.

Aus der Aufgabenstellung ergeben sich vier zentrale Forschungsfragen:

1. Wie stark verbessert das Finetuning auf den projektspezifischen Tiefgaragendaten ein vortrainiertes 3D-Detektionsmodell?
2. Welche Unterschiede bestehen zwischen den Einzelsensoransichten `os0` und `os1` und der fusionierten Ansicht `merged` ?
3. Zeigt sich ein Fusionsvorteil eher beim bloßen Finden eines Objekts oder bei der räumlich präzisen Lokalisierung?
4. Welche typischen Fehlerbilder und praktischen Laufzeitgrenzen besitzt die entwickelte Verarbeitungskette?

Der Fokus liegt auf drei Klassen: `person`, `bicycle` und `car`. Die wissenschaftliche Hauptaussage soll nicht aus einzelnen Beispielbildern oder einem einzigen zufälligen Split abgeleitet werden, sondern aus vollständig ungesesehenen Aufnahmen unter einem für alle drei Ansichten gepaarten Protokoll.

2. Datengrundlage

2.1 Sensoraufbau und Ansichten

Die Szene wird von zwei Ouster-LiDAR-Sensoren mit einer Aufnahme­rate von ungefähr 10 Hz erfasst. Jeder Sensor besitzt zunächst ein eigenes Koordinatensystem. Aus den Rohdaten werden drei Eingabevarianten erzeugt:

- `os0` : transformierte Punktwolke des ersten Sensors,
- `os1` : transformierte Punktwolke des zweiten Sensors,
- `merged` : geometrisch registrierte und zusammengefügte Punktwolke beider Sensoren.

Eine Einzelsensor-Punktwolke enthält typischerweise ungefähr 105.000 Punkte, die fusionierte Punktwolke ungefähr 210.000 Punkte. Die Fusion erhöht damit die Punktdichte und ergänzt verdeckte Objektseiten, vergrößert aber zugleich die zu verarbeitende Datenmenge und den sichtbaren Hintergrund.

2.2 Aufgezeichnete Experimente

Am 9. Oktober 2025 wurden neun Bewegungsaufnahmen in derselben Tiefgaragenszene erstellt:

Experimente	Bewegte Zielklasse
1–3	Auto
4–6	Fahrrad
7–9	Person

Neben dem jeweiligen bewegten Zielobjekt enthält die Szene zahlreiche statische Objekte, insbesondere geparkte Fahrzeuge. Diese statischen Objekte sind für eine realistische Detektion relevant, dürfen bei der Interpretation der Generalisierungsleistung aber nicht mit vollständig neuen Objektinstanzen verwechselt werden: Sie stehen über viele Aufnahmen hinweg an denselben Positionen.

Für die abschließende Cross-Validation wird ausschließlich die Schnittmenge der gültigen Zeitstempel aller drei Ansichten verwendet. Dadurch erhält jede Ansicht dieselben 2.122 physischen Frames. Die Annotationen bleiben dennoch ansichtsspezifisch, weil ein Objekt je nach Sensorabdeckung und Sichtbarkeit nicht in jeder Ansicht in exakt denselben Frames annotiert ist.

2.3 Annotationen

Die Ground-Truth-Annotationen bestehen aus orientierten dreidimensionalen Bounding Boxes. Für jede Box werden Klasse, Position, Abmessungen und Orientierung gespeichert. Zusätzlich kennzeichnet ein `static`-Attribut statische Objekte. Die finalen Labels wurden mit dem projektspezifischen Editor `experiment/manual_bbox_editor.py` geprüft und korrigiert.

Die ansichtsspezifischen Annotationen sind für den regulären Betrieb sinnvoll, begrenzen aber einen direkten Klassenvergleich zwischen den Ansichten. Beim bewegten Auto ist die Vergleichsmenge exakt gepaart (`n=339` in jeder Ansicht). Bei Person und Fahrrad unterscheiden sich die GT-Zahlen. Beispielsweise enthält die gepoolte Fahrradauswertung `718` Instanzen für `merged`, `627` für `os0` und `581` für `os1`.

Diese Differenz ist besonders wichtig für die Interpretation des Fahrrad-AP30: `os0` wird teilweise nur auf dem kürzeren, gut sichtbaren Abschnitt einer Trajektorie bewertet, während `merged` durch die größere Abdeckung zusätzliche und weiter entfernte Objektpositionen enthält. Der AP30-Vorsprung von `os0` darf deshalb nicht ohne Einschränkung als grundsätzliche Überlegenheit eines Einzelsensors interpretiert werden.

3. Datenaufbereitung und Sensorfusion

3.1 Registrierung und Merge

Die Merge-Pipeline ist in `experiment/pcd_merge.py` implementiert. Sie führt für jedes Sensorpaar folgende Schritte aus:

1. Laden der beiden Punktwolken und ihrer Intensitätswerte,
2. Entfernen statistischer Ausreißer,
3. Anwenden einer manuell bestimmten Vorabtransformation,
4. Voxel-Downsampling und Normalenschätzung,
5. Feinausrichtung durch Iterative Closest Point (ICP),
6. Konkatenation der transformierten Punkte.

Die beiden Sensoren sind fest montiert. Für einen späteren Online-Betrieb wäre deshalb eine einmalig auf einer geeigneten statischen Szene bestimmte Extrinsik vorzuziehen. Die aktuelle Implementierung berechnet die ICP-Korrektur dagegen für jeden Frame neu. Das ist für die Offline-Erzeugung der Projektdaten verwendbar, aber weder laufeitoptimal noch als endgültige Live-Pipeline zu verstehen.

3.2 Konvertierung in das Trainingsformat

MMDetection3D verarbeitet die Daten in einer KITTI-ähnlichen Repräsentation. Eigene Converter übertragen Punktwolken und Labels in dieses Format und erzeugen die benötigten Info-PKLs. Dabei wurden mehrere geometrische und metrische Fehler identifiziert und korrigiert:

- Der Boden lag durch eine fehlerhafte z-Transformation außerhalb des vorgesehenen Punktwolkenbereichs. Dadurch wurden Boden und untere Objektteile abgeschnitten.
- Der Label-Editor speichert die z-Koordinate im Boxzentrum, während die Trainingspipeline an einer Stelle die Boxunterkante erwartete. Ohne Korrektur schwebten die Boxen um eine halbe Objekthöhe zu hoch.
- Intensitäten wurden ursprünglich frameabhängig normiert. Sie werden nun mit einer festen Skala verarbeitet, sodass gleiche Intensitätswerte über Frames hinweg dieselbe Bedeutung besitzen.
- Die frühere Metrik mittelte AP pro Frame und wertete Frames ohne Instanz der betrachteten Klasse als Null. Dies begrenzte insbesondere die Fahrrad-AP künstlich. Die aktuelle Implementierung berechnet datensatzweite AP.

Alle maßgeblichen Trainings- und Cross-Validation-Ergebnisse basieren auf dem korrigierten Datenstand. Frühere Resultate mit abgeschnittenem Boden, verschobenen Boxen oder der fehlerhaften Pro-Frame-Metrik sind nicht vergleichbar.

4. Modelle und Training

4.1 PointPillars

PointPillars wandelt die unregelmäßige Punktwolke in ein Raster senkrechter Säulen, sogenannter Pillars, um. Innerhalb jedes Pillars werden die Punkte zu einem Merkmalsvektor verdichtet. Anschließend verarbeitet ein zweidimensionales Backbone die entstehende Bird's-Eye-View-Repräsentation und sagt orientierte 3D-Boxen voraus.

Das Modell wird nicht von Grund auf neu trainiert. Ausgangspunkt ist ein auf KITTI vortrainierter Drei-Klassen-Checkpoint. Dieses Vorwissen wird durch Finetuning auf die Tiefgaragenszene angepasst. Für jeden Fold und jede Ansicht wird ein eigenes Modell trainiert. Insgesamt entstehen damit neun evaluierbare PointPillars-Foldmodelle.

Die wesentlichen Trainingsparameter sind:

Parameter	Festgelegter Wert
Initialisierung	KITTI-Drei-Klassen-Checkpoint
Trainingsdauer	50 Epochen
Zufallsseed	42
Klassen	Person, Fahrrad, Auto
Checkpoint-Auswahl	höchste Validierungs-mAP
GT-Sampling	Person 8, Fahrrad 10

Für jede Fold-/Ansichtskombination wird die GT-Sampling-Datenbank ausschließlich aus deren Trainingsframes erzeugt. Test- und Validierungsobjekte können daher nicht durch Copy-Paste-Augmentierung in das Training gelangen.

4.2 Klassenungleichgewicht und GT-Sampling

In den Trainingsdaten kommen deutlich mehr Autos als Fahrräder vor; im früheren merged-Trainingssplit lag das Verhältnis ungefähr bei **22:1**. GT-Sampling fügt zusätzliche Personen- und Fahrradinstanzen aus anderen Trainingsframes in die aktuelle Trainingsszene ein. Dadurch steigt die Variabilität der seltenen Klassen, ohne Frames aus Validierung oder Test zu verwenden.

Frühere kontrollierte Ablationen zeigten, dass GT-Sampling die Fahrrad-Detektion verbessert. Einfaches Frame-Oversampling war weniger wirksam. Ein Filter für Punkte unterhalb des Bodens reduzierte die Fehldetektionen nicht und verschlechterte andere Ergebnisse; er wurde deshalb nicht in die Standardpipeline übernommen.

4.3 Architekturvergleich mit CenterPoint

Zusätzlich wurde CenterPoint unter demselben experiment-held-out Protokoll trainiert. CenterPoint ist im Gegensatz zum anchorbasierten PointPillars ein anchorfreier Detektor, der Objektzentren über eine Heatmap vorhersagt. Der Vergleich dient als Robustheitsprüfung der Modellwahl, nicht als nachträgliche Optimierung des Testprotokolls.

Auch bei CenterPoint ist **merged** in jedem Fold die beste Ansicht. Die PointPillars-Foldmittel liegen jedoch in allen drei Ansichten höher:

Ansicht	PointPillars	CenterPoint
merged	0,798	0,751
os0	0,777	0,659
os1	0,770	0,723

Der Abstand entsteht vor allem durch die schwächere Lokalisierung von CenterPoint bei strengeren IoU-Schwellen. Für die weitere Ergebnisdiskussion bleibt PointPillars deshalb das Hauptmodell.

5. Evaluationsprotokoll

5.1 Warum der frühere temporale Split ersetzt wurde

Die erste Auswertung verwendete innerhalb jedes Experiments eine zeitliche 80/10/10-Aufteilung. Im Fall der Autoaufnahmen lagen die Testframes damit am Ende der Trajektorie. Splitzugehörigkeit und Objektposition waren gekoppelt. Der sehr niedrige damalige dynamische Auto-AP30 von `os1=0,09` beschrieb somit nicht die allgemeine Qualität von `os1`, sondern die Generalisierung auf diesen letzten räumlichen Trajektorienabschnitt.

Dieser Befund darf nicht mehr als Hauptresultat verwendet werden. Die Cross-Validation mit vollständig zurückgehaltenen Experimenten ersetzt den temporalen Split als wissenschaftliche Hauptbewertung.

5.2 Experiment-held-out Cross-Validation

Das Protokoll wurde am 11. Juli 2026 vor der Sichtung der Cross-Validation-Testergebnisse eingefroren. Die drei Folds sind:

Fold	Vollständig ungesehene Testexperimente
1	1 Auto, 4 Fahrrad, 7 Person
2	2 Auto, 5 Fahrrad, 8 Person
3	3 Auto, 6 Fahrrad, 9 Person

Innerhalb der jeweils übrigen sechs Experimente werden die letzten zehn Prozent als Validierungsdaten verwendet. Die zehn davorliegenden Frames pro Trainingsexperiment werden als zeitlicher Guard ausgeschlossen. Die vollständigen Testexperimente werden weder für das Training noch für die Checkpoint-Auswahl verwendet.

Fold	Training	Validierung	Test	Guard
1	1.239	146	677	60
2	1.172	137	753	60
3	1.227	143	692	60

Alle drei Ansichten erhalten pro Fold identische physische Zeitstempel. Damit ist der View-Vergleich zeitlich gepaart. Die bereits erwähnten ansichtsspezifischen Labels bleiben jedoch erhalten.

5.3 Metriken

Eine Vorhersage gilt als Treffer, wenn ihre dreidimensionale Intersection over Union (IoU) mit einer noch nicht zugeordneten Ground-Truth-Box derselben Klasse den betrachteten Schwellwert erreicht. Verwendet werden `AP30`, `AP40`, `AP50` und `AP60`:

- `AP30` bewertet überwiegend, ob das Objekt ungefähr gefunden wurde.
- `AP60` verlangt eine deutlich präzisere räumliche Lokalisierung.
- Der Klassen-mAP mittelt über `AP30` bis `AP60`.
- Der Gesamt-mAP mittelt zusätzlich über die drei Klassen.

Die AP wird als datensatzweite AP11 berechnet. Vorhersagen werden nach ihrem Konfidenzscore sortiert; Matching bleibt frameweise, die Precision-Recall-Kurve wird jedoch aus der gesamten Testmenge aufgebaut.

5.4 Fold-Mittel und gepoolte Out-of-Fold-Auswertung

Die Fold-Ergebnisse sind die primäre Generalisierungsschätzung. Aus ihnen werden Mittelwert und Stichproben-Standardabweichung berechnet. Zusätzlich werden die Vorhersagen aller drei Testfolds zu einer gepoolten Out-of-Fold-Auswertung zusammengeführt. Dabei wurde jeder Frame genau von dem Modell vorhergesagt, für das sein vollständiges Experiment ungesehen war.

Die gepoolte AP wird einmal auf der gemeinsamen Rangliste aller Out-of-Fold-Vorhersagen berechnet. Sie ist deshalb nicht identisch mit dem arithmetischen Mittel dreier AP-Werte. Da die Konfidenzscores der drei Foldmodelle unterschiedlich kalibriert sein können, ergänzt der gepoolte Wert die Foldanalyse, ersetzt sie aber nicht.

5.5 Offizielle und labelbasierte Beweg-/Statisch-Auswertung

Die offizielle dynamische Teilbewertung ignoriert eine Vorhersage auf einem statischen Objekt nur, wenn diese am jeweiligen Evaluationsschwellwert ausreichend mit der statischen GT-Box überlappt. Eine etwas ungenau lokalisierte, aber eindeutig einem geparkten Auto zuordenbare Box kann dadurch bei `AP60` als False Positive der dynamischen Rangliste erscheinen.

Deshalb existiert zusätzlich eine benannte labelbasierte Variante. Sie nutzt das manuelle `static`-Attribut und ignoriert Vorhersagen auf Nichtzielobjekten bereits ab IoU `0,25`. Die regulären All-Object-Metriken bleiben dabei bit-identisch; nur die Teilranglisten für bewegte und statische Objekte ändern sich. Die offizielle Auswertung bleibt die Vergleichsreferenz, während die labelbasierte Variante die interpretierbare Analyse der bewegten Objekte liefert.

6. Ergebnisse

6.1 Gesamtleistung von PointPillars

Ansicht	Fold 1	Fold 2	Fold 3	Mittel ± Std.	Gepoolt OOF
merged	0,840	0,786	0,768	0,798 ± 0,037	0,789
os0	0,793	0,781	0,757	0,777 ± 0,018	0,759
os1	0,801	0,751	0,759	0,770 ± 0,027	0,765

merged erzielt in jedem Fold den höchsten Gesamt-mAP. Der mittlere Vorsprung beträgt ungefähr **0,021** gegenüber **os0** und **0,028** gegenüber **os1**. Bei nur drei Folds ist das kein starker Signifikanznachweis. Es ist jedoch ein konsistenter Hinweis darauf, dass Fusion die ausgewogenste Gesamtleistung liefert und in keinem Fold von einer Einzelsicht übertroffen wird.

6.2 Bewegte Objekte

Die folgende Tabelle verwendet die labelbasierte Bewegt-/Statisch-Variante, die auch der Abschlusspräsentation zugrunde liegt:

Ansicht	Person AP30 / AP60	Fahrrad AP30 / AP60	Auto AP30 / AP60
merged	0,901 / 0,729	0,800 / 0,668	0,891 / 0,883
os0	0,653 / 0,370	0,895 / 0,378	0,885 / 0,856
os1	0,896 / 0,426	0,744 / 0,529	0,832 / 0,789

Die Tabelle trennt zwei Aspekte:

- Bei AP30 finden alle Ansichten alle drei bewegten Klassen grundsätzlich.
- Bei AP60 liegt **merged** in allen Klassen vorn. Der Fusionsvorteil zeigt sich damit besonders in der räumlichen Präzision.

Beim bewegten Auto liegen die drei Ansichten wesentlich näher zusammen als im früheren temporalen Split. Alle drei Ansichten erkennen das Auto gut. Die defensible Schlussfolgerung lautet daher nicht, dass Fusion für die Autoerkennung notwendig sei, sondern dass Fusion über Klassen und IoU-Schwellen hinweg die beste Balance bietet.

6.3 Warum ist Fahrrad-AP30 bei os0 höher?

os0 erreicht bei Fahrrädern einen höheren AP30, während **merged** bei AP60 deutlich führt. Ein Teil des AP30-Unterschieds ist ein Sichtbarkeits- und Label-Effekt. Die Ansichten enthalten nicht dieselbe Fahrrad-GT-Menge.

Besonders deutlich ist Experiment 5:

Ansicht	Fahrrad-GT	AP30	AP60
merged	310	0,727	0,611
os0	244	0,907	0,425

In den Rohannotationen liegen die zusätzlichen **merged**-Fahrradframes gegenüber **os0** überwiegend weiter entfernt. **os0** wird damit teilweise nur auf dem kürzeren, gut sichtbaren Trajektorienabschnitt bewertet. Eine objektweise vollständig faire Aussage darüber, ob **merged** dieselben Fahrräder schlechter findet, würde eine zusätzliche Auswertung auf einer gemeinsamen Referenz-GT-Menge erfordern.

Unabhängig davon zeigt AP60, dass die von **merged** gefundenen Fahrräder räumlich wesentlich genauer lokalisiert werden. Die kurze Interpretation lautet daher: **os0** besitzt in seiner eigenen Labelmenge die vollständigere Groberkennung, die Fusion liefert die präziseren Boxen.

6.4 Offizielle dynamische Auswertung und AP60-Artefakt

In der offiziellen dynamischen Auswertung beträgt der Auto-AP30/AP60 **0,877/0,739** für **merged**, **0,885/0,847** für **os0** und **0,831/0,783** für **os1**. Der niedrige offizielle AP60 von **merged** entsteht nicht primär durch eine schlechte Box auf dem bewegten Auto. Die beste merged-Box auf dem bewegten Auto hat im Median sogar die höchste IoU der drei Ansichten (**0,848**).

Der Haupttreiber ist ein sensornahe geparktes Fahrzeug. Zahlreiche hochkonfidente merged-Vorhersagen liegen dort bei IoU **0,25–0,60**. Sie werden bei der offiziellen AP60-Teilbewertung nicht mehr als statische Ignore-Treffer erkannt und erscheinen als False Positives in der dynamischen Rangliste. Die labelbasierte Variante ordnet diese Vorhersagen dem statischen Objekt zu; der merged-Auto-AP60 steigt dadurch von **0,739** auf **0,883**.

6.5 Vergleich zu CenterPoint

CenterPoint bestätigt das qualitative View-Ranking: **merged** ist auch dort in jedem Fold die beste Ansicht. Gleichzeitig liegt CenterPoint im Gesamt-mAP unter PointPillars. Unter der labelbasierten dynamischen Auswertung ist die AP60-Lücke besonders bei Fahrrädern sichtbar. Der Fusionsbefund hängt somit nicht ausschließlich an der anchorbasierten PointPillars-Architektur; die höhere absolute Leistung in diesem Projekt liefert jedoch PointPillars.

7. Qualitative Fehleranalyse

7.1 Definition der Geisterboxen

Für die generalisierte OOF-Analyse wird eine Geisterbox als Vorhersage mit Score mindestens 0,3 definiert, die sich keiner noch unbenutzten GT-Box derselben Klasse bei 3D-IoU mindestens 0,3 zuordnen lässt. Diese Definition umfasst nicht nur leere Halluzinationen, sondern auch Duplikate, falsch klassifizierte reale Strukturen und schlecht lokalisierte Boxen.

Auf den 2.122 gemeinsamen Testframes ergeben sich:

Ansicht	Person	Fahrrad	Auto	Gesamt
merged	510	315	159	984
os0	948	157	415	1.520
os1	329	372	248	949

Die Fehler sind nicht auf Fahrräder beschränkt. os0 erzeugt beispielsweise deutlich mehr Person-Geisterboxen, während merged mehr Fahrrad-Geisterboxen als os0 enthält.

7.2 Plausible Ursachen

Die detaillierte Fahrradforensik zeigt drei wiederkehrende Gruppen:

1. Reale statische oder nicht gelabelte Strukturen werden als Fahrrad interpretiert.
2. Sparse Reflexions- und Unterbodenpunkte können lokale Aktivierungen auslösen.
3. Vorhersagen treten wiederholt an Positionen auf, an denen Fahrräder in den Trainingsaufnahmen vorkamen. Dies deutet auf eine ortsgebundene Szenenmemorierung hin.

Ein Unterbodenfilter reduzierte die Geisterboxen in einer Ablation nicht. Die Spiegelungshypothese ist daher nicht der dominante Mechanismus.

Teilweise ragen Fahrrad- oder Personenboxen in die Ground-Truth-Box eines Autos. Das ist als klassenübergreifende Mehrfachhypothese plausibel: Dünn abgetastete Fahrzeugkanten oder das Heck können gleichzeitig einen fahrradähnlichen Anchor aktivieren. Die standardmäßige Non-Maximum Suppression arbeitet klassenweise. Eine korrekte Autobox unterdrückt deshalb keine zusätzliche Fahrradbox. Da die Zusatzbox keine Fahrrad-GT trifft, zählt sie in der Fahrradwertung als False Positive, auch wenn sie ein Auto überlappt.

Eine getestete Cross-Class-NMS entfernte vollständig enthaltene klassenübergreifende Zusatzboxen und veränderte die Metriken nicht. Sie ist als Ausgabebereinigung vertretbar, sollte aber nicht nachträglich anhand der Cross-Validation-Testdaten optimiert werden.

7.3 Praktische Gegenmaßnahmen

Für eine spätere Anwendung bieten sich folgende Maßnahmen an:

- pro Klasse auf Validierungsdaten gewählte Konfidenzschwellen,
- zeitliche Trackbestätigung statt Entscheidungen aus einzelnen Frames,
- Hintergrundunterstützung oder eine statische Szenenkarte,
- Cross-Class-NMS als konservative Ausgabebereinigung,
- zusätzliche Trainingsszenen zur Verringerung der Ortsmemorierung.

8. Laufzeit

8.1 Modellinferenz

Die Laufzeiten wurden mit Batchgröße 1 auf einer Tesla V100-SXM3-32GB gemessen. Die Messung umfasst die Modellpipeline einschließlich Datenverarbeitung und Voxelisierung auf bereits vorbereiteten Ansichtsdaten.

Ansicht	Durchsatz	Zeit pro Frame	Typische Punktzahl
merged	11,7 fps	85 ms	ca. 210.000
os0	22,3 fps	45 ms	ca. 105.000
os1	23,5 fps	43 ms	ca. 105.000

Bei einer Sensorfrequenz von **10 Hz** steht pro Frame ein Budget von **100 ms** zur Verfügung. Die Modellinferenz auf der bereits fusionierten Punktwolke bleibt mit **85 ms** darunter. Daraus folgt aber nur, dass die Modellinferenz 10-Hz-fähig ist.

8.2 Merge-Zeit und Ende-zu-Ende-Einordnung

Die vorhandene Offline-Merge-Pipeline wurde auf einer lokalen CPU mit acht parallelen Workern gemessen. Über **3.327** Frames beträgt die mediane Bearbeitungszeit **2,25 s** pro Frame, der Mittelwert **2,20 s**. Enthalten sind PCD-Laden, statistischer Filter, feste Vorabtransformation, Downsampling, Normalenschätzung und per-Frame-ICP.

Würde diese Pipeline unverändert seriell vor der Inferenz ausgeführt, läge die Ende-zu-Ende-Latenz grob bei:

$$2,25 \text{ s Merge} + 0,085 \text{ s Inferenz} \approx 2,34 \text{ s pro Frame}$$

Das wäre nicht echtzeitfähig. Bei fest installierten Sensoren kann die Extrinsic jedoch einmalig offline bestimmt werden. Online wären dann nur Zeitsynchronisation, feste Transformation und Konkatenation erforderlich. Dieser optimierte Pfad wurde bislang nicht implementiert und gemessen.

Nach der merged-Inferenz verbleiben in einer seriellen 10-Hz-Pipeline nur ungefähr **15 ms** für Merge und sonstigen Overhead. Eine parallele CPU-/GPU- Pipeline könnte den Durchsatz verbessern, die Ende-zu-Ende-Latenz muss dennoch separat erfasst werden. Die korrekte Aussage ist deshalb:

Die Modellinferenz auf bereits fusionierten Daten ist 10-Hz-fähig; die Echtzeitfähigkeit des vollständigen Online-Fusionssystems ist noch nicht nachgewiesen.

9. Gültigkeit und Grenzen

9.1 Interne Gültigkeit

Für die Cross-Validation wurden folgende Schutzmaßnahmen umgesetzt:

- vollständige Testexperimente sind von Training und Checkpoint-Auswahl ausgeschlossen,
- Train-, Validierungs- und Testframes sind disjunkt,
- GT-Sampling-Datenbanken enthalten ausschließlich Trainingsobjekte,
- ein zeitlicher Guard trennt Training und Validierung,
- der Zufallsseed ist fixiert,
- alle Ansichten verwenden dieselben gültigen physischen Zeitstempel,
- die offiziellen Fold-mAP-Werte wurden aus den Prediction-Dateien mit einer maximalen Abweichung von $2,22\text{e-}16$ reproduziert.

9.2 Einschränkungen der Aussagekraft

Die Ergebnisse besitzen folgende Grenzen:

1. Alle neun Experimente stammen aus derselben Tiefgaragenszene. Die Cross-Validation misst Generalisierung auf ungesehene Aufnahmen und Trajektorien in dieser Szene, nicht auf neue Orte.
2. Viele statische Fahrzeuge erscheinen in mehreren Folds an denselben Positionen. All-Object-Werte enthalten deshalb einen Anteil Szenenwiedererkennung.
3. Die Zahl physisch verschiedener Zielobjekte und Personen ist klein.
4. Person- und Fahrradlabels sind zwischen Ansichten nicht vollständig objektweise gepaart.
5. Drei Folds erlauben nur eine vorsichtige Interpretation der Streuung und keine starke Signifikanzbehauptung.
6. Gepoolte OOF-AP kombiniert Scores verschiedener Foldmodelle, die unterschiedlich kalibriert sein können.
7. Die Live-Laufzeit des optimierten Online-Merges wurde noch nicht gemessen.

10. Schlussfolgerung

Das Projekt zeigt, dass ein auf KITTI vortrainiertes 3D-Detektionsmodell durch Finetuning erfolgreich auf eine fest installierte Tiefgaragenszene angepasst werden kann. PointPillars liefert mit der fusionierten Punktwolke in jedem Cross-Validation-Fold den höchsten Gesamt-mAP. Der Fusionsvorteil ist moderat, aber konsistent und zeigt sich besonders in der präzisen Lokalisierung bewegter Personen und Fahrräder.

Die Fusion ist dagegen nicht notwendig, um das bewegte Auto grundsätzlich zu erkennen. Alle drei Ansichten erreichen auf vollständig ungesehenen Autoaufnahmen eine hohe AP30; **os0** ist leicht am besten. Der frühere starke **os1**-Einbruch war ein Artefakt der zeitlich und räumlich gekoppelten Testaufteilung. Dieses Ergebnis unterstreicht, wie stark wissenschaftliche Schlussfolgerungen von einem passenden Evaluationsdesign abhängen.

Die aussagekräftigste Gesamtformulierung lautet:

Die Multisensorfusion liefert die beste ausgewogene Gesamtleistung und die präziseste Lokalisierung, ist aber nicht in jeder Klasse und bei jeder Metrik die beste Einzelansicht.

Für einen späteren Einsatz sind vor allem ein finaler Refit des ausgewählten Modells, ein gemessener Online-Merge, validierungsbasierte Betriebsschwellen und zeitliches Tracking erforderlich.

11. Reproduzierbarkeit und Projektartefakte

11.1 Zentrale Implementierungen

- Cross-Validation-Splits: `mmdetection3d/tools/dataset_converters/create_exp_crossval_splits.py`
- PointPillars-CV-Konfiguration: `mmdetection3d/configs/pointpillars/pointpillars_hv_secfpn_8xb6-50e_exp_crossval_gtsample.py`
- Trainingssteuerung: `mmdetection3d/tools/run_exp_crossval.sh`
- Cross-Validation-Auswertung: `mmdetection3d/tools/analysis_tools/exp_eval_crossval.py`
- Geisterboxanalyse: `mmdetection3d/tools/analysis_tools/exp_ghost_boxes_crossval.py`
- Punktwolken-Merge: `experiment/pcd_merge.py`
- Label-Editor: `experiment/manual_bbox_editor.py`

11.2 Primäre Ergebnisquellen

- `results/CROSS_VALIDATION.md` : eingefrorenes Evaluationsprotokoll
- `results/CROSS_VALIDATION_RESULTS.md` : offizielle PointPillars-Ergebnisse
- `results/CROSS_VALIDATION_STATIC_AWARE.md` : labelbasierte Teilbewertung
- `results/CENTERPOINT_CV_STATIC_AWARE.md` : CenterPoint-Vergleich
- `results/GHOST_BOXES.json` : generalisierte OOF-Fehlerzählung
- `results/DATA_AUDIT.md` : Daten-, Metrik- und Ursachenanalyse
- `results/ABLATION_BICYCLE.md` : frühere kontrollierte Ablationen

11.3 Präsentationsmaterial

Das primäre qualitative Video ist `results/videos/exp1_cv_full_three_views_oblique.mp4`. Es zeigt alle 105 gemeinsamen gültigen Frames von Experiment 1 mit den drei Fold-1-Modellen, für die das vollständige Experiment während Training und Checkpoint-Auswahl ungesehen war.

Ältere Videos des temporalen 11-Frame-Testsegments sind nur historische Artefakte. Sie dürfen nicht als Beleg dafür verwendet werden, dass `os1` das bewegte Auto generell nicht erkennen könne.

12. Offene Arbeiten

Für die nächste Überarbeitung beziehungsweise einen späteren Deployment-Stand sind folgende Punkte offen:

- wissenschaftliche Quellen und Literaturverweise ergänzen,
- Abbildungen und Tabellen nummerieren und im Text referenzieren,
- gemeinsame Fahrrad-GT-Auswertung für einen streng objektweise gepaarten View-Vergleich durchführen,
- Fehler nach kontinuierlicher Position, Distanz und Punktunterstützung aufschlüsseln,
- finalen Refit für die ausgewählte Ansicht und eine vorab festgelegte Trainingsdauer auf allen gültigen Daten trainieren,
- Online-Merge mit fester Extrinsic implementieren und Ende-zu-Ende-Latenz messen,
- Betriebsschwellen ausschließlich aus Validierungsfolds bestimmen,
- Tracking und Hintergrundmodell als separate, klar benannte Erweiterungen evaluieren.

Ein finaler Refit ist nicht mit einem neuen unabhängigen Testergebnis zu verwechseln. Die Cross-Validation bleibt die wissenschaftliche Leistungsschätzung; der Refit wäre das spätere Inferenzartefakt.

Automatisch erzeugt aus `DOKUMENTATION_ENTWURF.md`. Maßgebliche Ergebnisquellen sind die im Abschnitt „Reproduzierbarkeit und Projektartefakte“ aufgeführten Cross-Validation-Reports.